

基于大模型的 软件架构风格智能助手

软件体系结构课程大作业

2026年X月

将 自然语言需求 → 可解释的架构推荐

作业目标与核心功能

能力	说明
需求分析	接收自然语言需求，提取 10 维度关键特征（高并发/实时性/安全性/可扩展性...）
架构推荐	推荐 ≥3 种候选架构风格，含分层/微服务/事件驱动等主流架构
决策支持	多维度对比矩阵 + 最终推荐 + 优缺点分析 + 风险评估
知识进化	可扩展知识库（10 种风格）+ 案例反馈学习机制

系统总体架构

用户（浏览器 / API）



架构风格智能助手（6 容器）

Frontend :3000

API Gateway :8000

Requirements Agent :8001

Matching Agent :8002

Evaluation Agent :8003

Knowledge Base :8004



LLM 服务（DeepSeek v4-flash）

OpenAI 兼容协议，可替换


LLM 是外部依赖而非系统内核，支持一键切换

微服务划分 (5+1)

服务	端口	职责	关键技术
api-gateway	8000	统一入口, 编排调用	FastAPI, httpx
requirements-agent	8001	特征提取 + LLM 补全	10 维词典, 否定过滤
matching-agent	8002	规则评分 + Top3	标签匹配, 专家规则
evaluation-agent	8003	LLM 推理 + 报告	DeepSeek, 混合推理
knowledge-base	8004	风格数据 + 反馈	JSON, 可扩展
frontend	3000	可视化展示	HTML, Mermaid.js

划分理由： 异构成分隔离 (规则 vs LLM) · 故障隔离 · 独立演进

Agent 协作机制



Pipeline-Agent 模式： 单一职责 · 数据驱动流转 · LLM 仅最后一环参与

LLM 集成方案

两套 Prompt 分工:

功能	t	角色	输出
llm_vote_style	0.0	strict judge	仅风格名
llm_summary	0.3	architecture reviewer	结构化中文报告

四层防护:

- 1. 🕒 20s 超时控制
- 2. 🛡️ try-except 全量捕获
- 3. 📋 降级为规则引擎格式化摘要
- 4. ⏮️ 未配置 Key 时自动跳过

LLM 完全不可用时，规则引擎独立运行，核心链路不中断

架构知识库设计

10 种架构风格 × 6 字段:

Layered · Microservices · Event-Driven · SOA · Hexagonal
Pipeline-Filter · CQRS · Serverless · Space-Based · Client-Server

每条风格含: `name` `tags` `best_for` `pros` `cons` `topology_mermaid`

扩展机制:

- `POST /styles` → 动态新增风格
- `POST /feedback` → 案例反馈收集
- `GET /feedback/stats` → 准确率统计

混合推理机制（核心创新）

规则引擎

（确定性・保下限）

✓ tags 匹配 +2/tag

✓ 额外专家规则 +1

✓ 主流白名单兜底

✓ 评分完全可追溯

LLM 增强

（语义性・提上限）

架构推荐全链路

输入：自然语言需求



[Step 1] 需求理解

- ├ 10 维度 × ~100 关键词匹配
- ├ filter_negation() 否定过滤
- ├ 命中 $\leq 2 \rightarrow$ LLM 语义补全 ($t=0.1$)



[Step 2] 架构匹配

- ├ score_style() 逐风格评分
- ├ 额外规则 + 主流白名单
- ├ Top3 候选精选



[Step 3] 混合评估

- ├ 规则排序 + LLM 投票 (+1)
- ├ LLM 生成结构化中文报告



输出：核心推荐 + 备选 + 矩阵 + 风险 + 拓扑图

可视化：对比矩阵与拓扑图

前端四区域：

区域	内容	数据来源
 推荐摘要	核心推荐 + 备选 + LLM 分析报告	evaluation-agent
 特征卡片	命中维度 + 关键词证据	requirements-agent
 对比矩阵	6 列：类型/风格/得分/理由/优点/缺点	evaluation-agent
 拓扑图	Mermaid.js 动态渲染	knowledge-base JSON

拓扑图不是静态图片 —— 10 种风格各有专属 Mermaid 定义，修改图只需改 JSON

系统演示（参考案例）

输入：

开发跨平台即时通讯系统，支持万人同时在线，消息实时可靠，后续扩展视频通话

输出：

步骤	结果
特征提取	高并发 实时性 可靠性 可扩展性
候选架构	Event-Driven(7分) + Microservices(5分) + CQRS(4分)
LLM 报告	3 条推荐理由 + √3 优点 + ×3 缺点 + 风险建议
拓扑图	Client→Gateway→Producer→EventBus→Consumers

测试验证

三层测试体系：

层级	工具	用例
单元测试	pytest	核心算法 4 条
冒烟测试	run_smoke.py	20 条快速验证
回归测试	run_regression.py	20 条 + 5 指标统计

回归测试结果（实测）：

指标	结果
通过率	100% (20/20)
Top3 完整率	100%
主流覆盖率	100%
推荐产出率	100%

python scripts/check_assignment.py → 21/21 全部通过

异常处理与可靠性

层级	措施
网关层	统一 502/500 · <code>trust_env=False</code> 绕过代理
LLM 层	20s 超时 · try-except · 降级摘要 · 自动跳过
前端层	防重复提交 · 错误分支不崩溃

容错性:

-  单 Agent 故障不影响网关
-  LLM 完全不可用 → 规则引擎独立输出完整推荐
-  `.env` 自动加载, Key 不硬编码

项目创新点

1. 混合推理机制

规则保下限 + LLM 提上限 + 三层证据可追溯

2. Pipeline-Agent 协作

职责单一体现在独立容器中，非单体内部模块划分

3. 数据驱动拓扑图

10 种风格 Mermaid 定义存于知识库，API 动态返回

4. 案例学习闭环

反馈收集 → 统计 → 可驱动自动权重更新

总结与展望

当前成果：

-  功能完整 — 需求→推荐→解释 闭环
-  测试充分 — 20/20 通过，全部指标 100%
-  工程完善 — 6 容器、日志、异常、降级
-  文档齐全 — 需求+架构+测试+答辩

后续改进：

- → 案例学习：反馈数据 → 自动权重更新
- → 知识库：JSON → Neo4j 图数据库
- → 性能：LLM 调用并行化 (-40% 时延)